Анализ данных Dota 2

Доминатор и винрейт
Обнаружение смурфов
Саммари матча

Роман Охопков — DE Сергей Голдаев — SA
Антон Кузьмин — PA Роман Хожанец — BA

Буткэмп по дата-инженерии, Томск, 12–15 ноября 2026. Обновлённые материалы: 14.11.2026

Задача и результат для заказчика

Игрок и аналитик

Связать тайминг первой покупки Доминатора с исходом матча и сравнить раннюю и позднюю группы.

Аналитик матчмейкинга

Ранжировать нетипичные профили для ручной проверки и объяснять вклад признаков.

Игрок и зритель

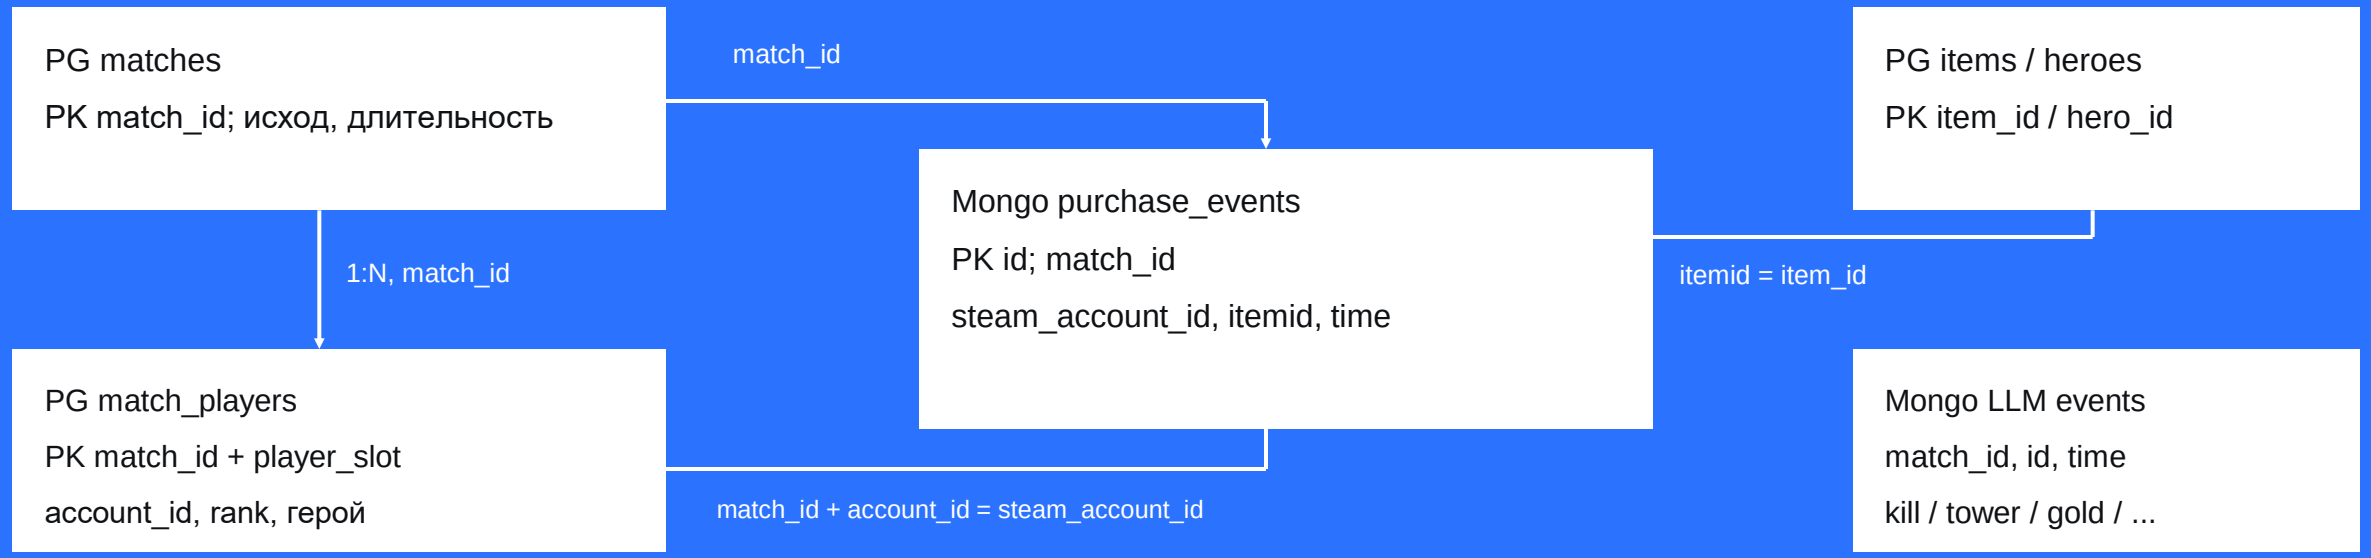
Получать короткий обзор матча по событиям с проверяемыми таймкодами и фактами.

Бизнес-вопросы и гипотезы

Гипотеза	Метрика	Данные
SQL: ранняя покупка связана с WR. Связь наличия предмета зависит от длительности	ΔWR ранние − поздние, цель +3 п.п. WR с/без предмета по длительности	Покупатель в матче / команда Первая покупка, исход, длительность
ML: нетипичный профиль выделяется относительно peers	AP, precision, recall, F1 Сравнение вариантов признаков	Статистика участника Автометки perf_z, ранг
LLM: факты позволяют составить полезный обзор. Проверка фактов снижает ошибки	Неподтверждённые утверждения Полнота, формат, хронология	События одного матча Входной JSON и итоговый текст

Цель +3 п.п. относится к SQL. Метрики ML измерены по автоматическим меткам

Данные: целевой контракт связей



Кейс	Гранулярность результата	Контроль качества
SQL	Покупатель в матче / команда в матче	Не смешивать две единицы анализа
ML	Участник матча, затем score	Ранг, отбор, зависимость по аккаунту
LLM	Событие с event_id / обзор матча	ID, факты, таймкод и порядок

Логическая схема. Фактический SQL разрешает повторы аккаунта через ROW_NUMBER; это требует DQ

Архитектура и витрины



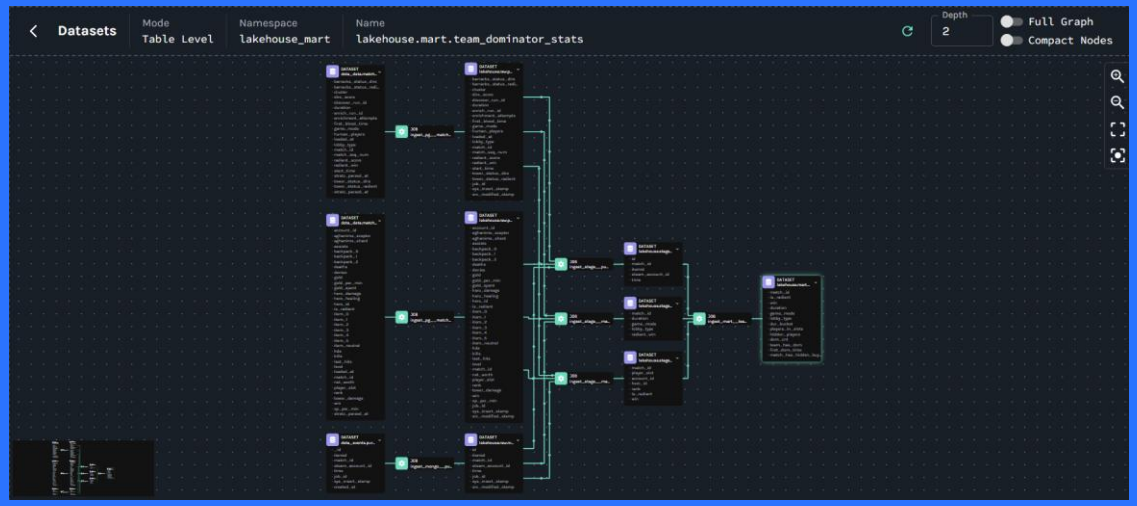
Объект	Назначение / объём	Обновление / SLA	Хранение
dom_buyers	Первые покупки ≈12 тыс. direct в графике	Часовой пересчёт* SLA не измерен	Срез до защиты +30 дней*
team_dominator_stats	Команда в матче без скрытых аккаунтов	После STAGE* SLA не измерен	До защиты +30 дней*
ML / LLM notebook	Эксперимент / один обзор	Ручные запуски DAG не подтверждён	Политика не задана

* Требования SQL-паспорта. Фактические настройки и версии снимков ещё нужно зафиксировать

Lineage подтверждён UI-скриншотами. SLA и расписания требуют отдельного протокола

ETL: фактический lineage

SQL в UI → проверка → сохранение → DAG платформы → запуск → DQ



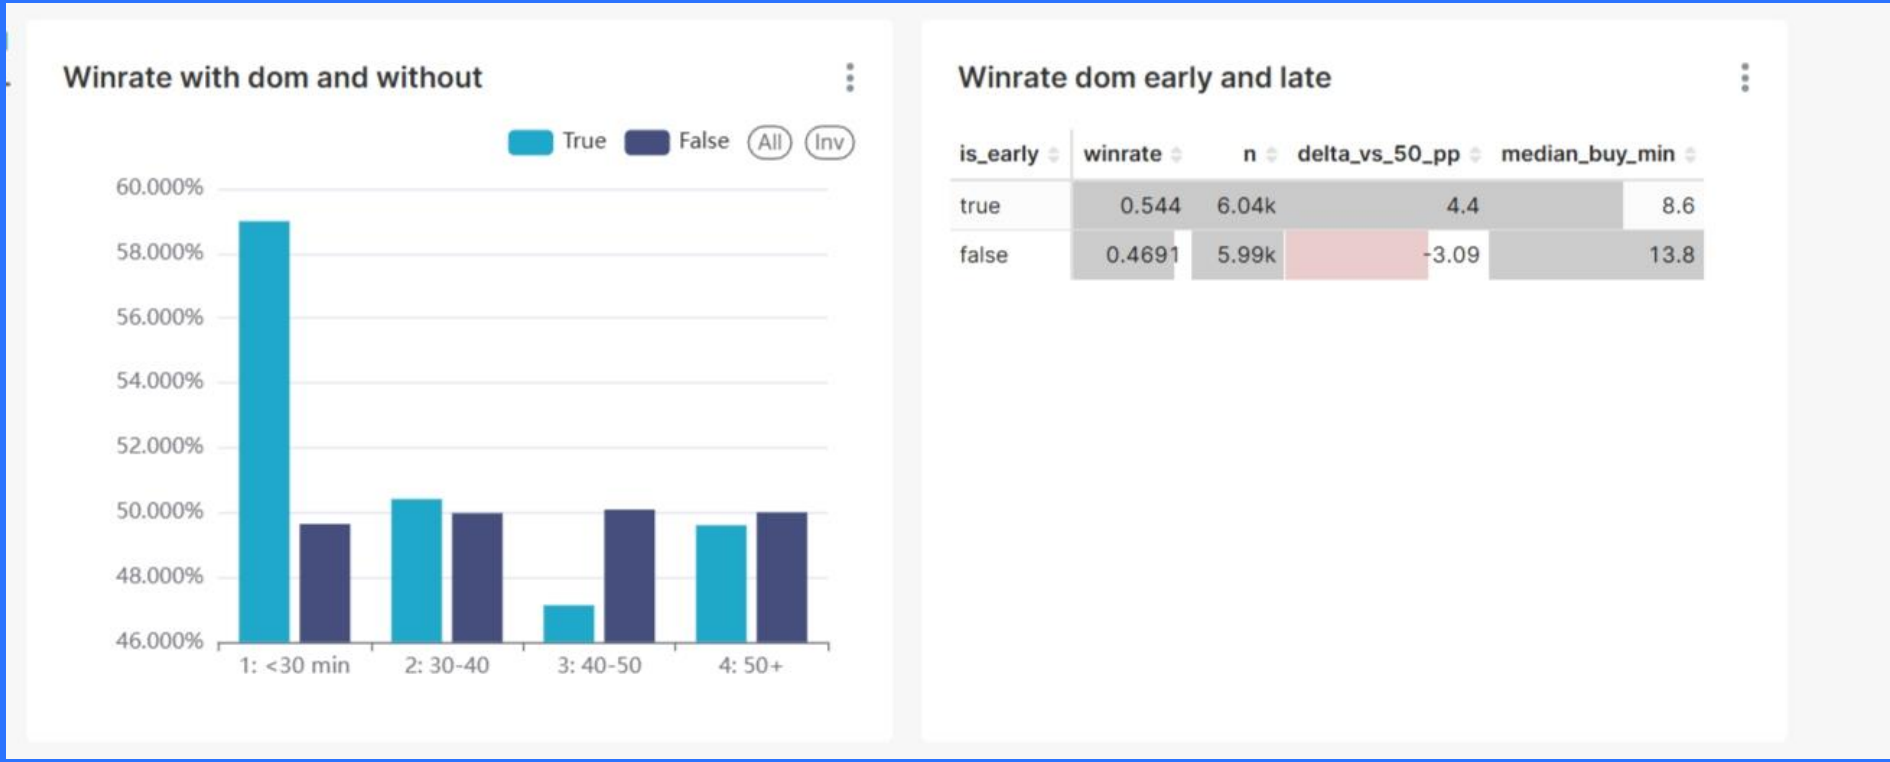
Число DAG / успешных запусков не установлено. Контроль: run_id, snapshot, ключи и row count

Поток	Вход / выход	Правило нового	Запуск / статус
SQL	STAGE → dom_buyers и team_dominator_stats	Пересборка по снимку версии входов фиксировать	Раз в час — требование UI-lineage есть
ML	PG match_players → признаки → CatBoost / SHAP	Новая выгрузка / run STAGE не вход notebook	Ручной эксперимент outputs сохранены
LLM	RAW events → JSON → описания → обзор	Выбор match_id версия фактов не задана	Ручной прогон 1 матч, 2 вызова

Реальный UI-артефакт: task/case1/lineage2.png. Он не заменяет протокол успешного DAG-run

SQL: ранние покупки и винрейт

54,40% ранние 46,91% поздние Δ = +7,49 п.п.



Winrate dom early and late

is_early	winrate	n	delta_vs_50_pp	median_buy_min
true	0.544	6.04k	4.4	8.6
false	0.4691	5.99k	-3.09	13.8

Команды с/без предмета: до 30 мин разрыв заметен, после 40 мин положительного разрыва нет.

Δ ранние/поздние выше цели точечно. Значимость и причинный эффект не установлены.

Реальный Superset: task/case1/1.1.png. Числа n на скриншоте округлены

ML: сохранённые результаты моделей

Train 26 663 Validation 6 674 Test 8 336

CatBoost. Автометка: известный ранг, tier ≤ 5 и perf_z ≥ 1,5

Модель	AP	Precision	Recall	F1	Порог
Baseline	0,3872	0,3871	0,4444	0,4138	0,18
Tuned	0,3880	0,3876	0,3086	0,3436	0,65

Положительных автометок в test: 162 из 8 336 (1,94%).

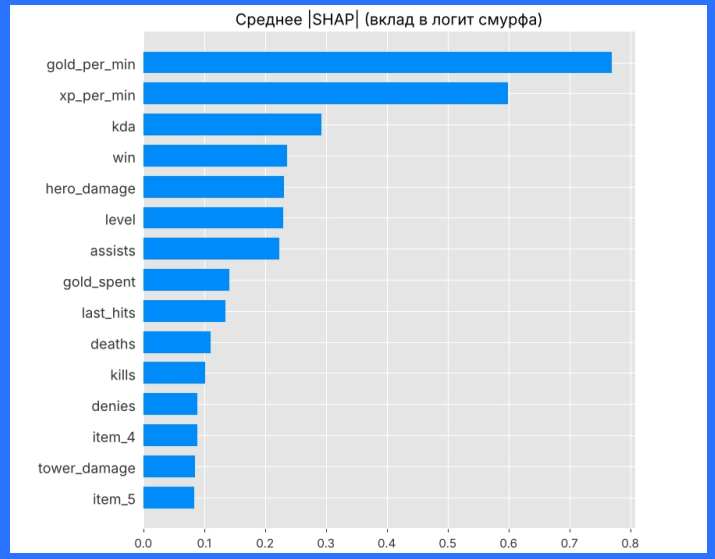
После tuning AP почти не изменился, F1 при выбранном пороге снизился.

Это качество воспроизведения автометок, а не подтверждение смурфинга.

Источник: outputs smurf_pipeline_fixed_with_outputs_1__1.ipynb. Метки автоматические

ML: роль ранга и объяснение прогноза

	f1	precision	recall	roc_auc	pr_auc	best_iter	thr	n_test	n_test_pos
full_raw / без ранга	0.4138	0.3871	0.4444	0.9635	0.3872	59.0	0.18	8336.0	162.0
full_raw / с рангом	0.5606	0.4976	0.6420	0.9801	0.6031	75.0	0.22	8336.0	162.0
no_label_inputs / без ранга	0.1769	0.1250	0.3025	0.8439	0.1010	204.0	0.07	8336.0	162.0
full_raw / unranked как 0	0.2078	0.2092	0.2065	0.9742	0.1860	111.0	0.18	25615.0	155.0

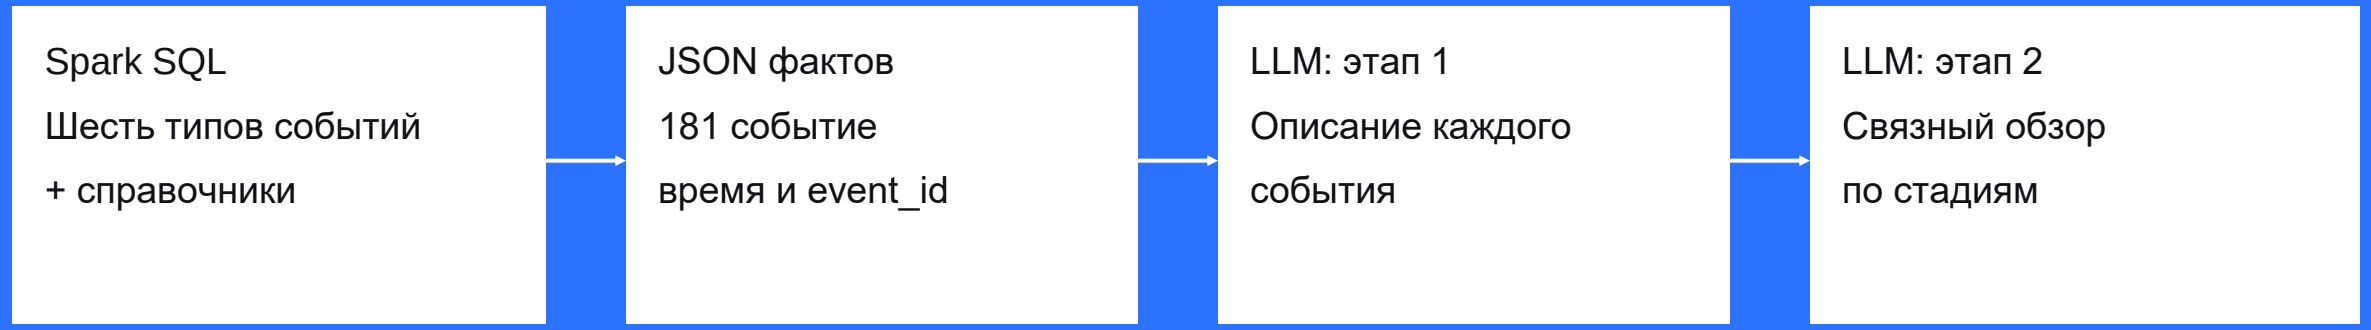


С рангом: AP 0,6031, F1 0,5606.

GPM и XPM дают наибольший вклад SHAP. Это согласуется с конструкцией автометок и требует проверки утечки.

Изображения из task/case2/2.4.png и 2.1.png. Сохранённые эксперименты, не новый запуск

LLM: подготовка фактов и генерация



Матч 9045752693: 181 событие, диапазон 0:15–24:52.

60 убийств, 66 покупок, 26 записей башен, 27 серий/мультикиллов, 2 байбека.

Диапазон событий не является подтверждённой длительностью матча.

Промпт ограничивает ответ фактами, но отдельного проверяющего этапа пока нет.

Модель в конфигурации обоих этапов: openai/gpt-5.4-nano

Источник: task/case3/case3.ipynb и паспорт. Один сохранённый прогон

LLM: демонстрация выявила ошибки

Проверка	Наблюдение	Следствие
Число описаний / ID	181 описание, 180 уникальных ID 4 несовпадения по позиции	Равенства длины недостаточно Нужна сверка множества и порядка
Таймкод эпизода	Queen of Pain против Axe: вход 5:11, обзор 5:16	В обзоре есть ошибка времени Нужна проверка каждого утверждения
Стадии и итог матча	4 абзаца при 2 стадиях входа Конец матча не дан во входе	Структура и вывод о завершении не подтверждаются данными

Генерация связного текста продемонстрирована. Фактическая точность и полезность обзора пока не подтверждены на контрольном наборе.

Источник: сохранённые вход и ответы case3.ipynb. Аудит event_id — локальный перерасчёт

Проверка гипотез: итог по трём кейсам

Кейс	Полученный результат	Статус гипотезы	Что нужно проверить
SQL	ΔWR ≈ +7,49 п.п. Разрыв с/без предмета зависит от длительности	Связь наблюдается цель превышена точечно	Snapshot, общий порог ДИ по match_id, DQ
ML	CatBoost, tuning, SHAP AP до 0,6031 с рангом	По автометкам есть измеренный результат	Ground truth, матчи/время утечки и воспроизводимость
LLM	Двухэтапный обзор одного матча получен	Демонстрация есть требования качества не пройдены	Валидация ID и фактов контрольный набор и A/B

Различаем наблюдаемый результат, интерпретацию и недостающую проверку

Выводы для заказчика

01 У ранних покупателей Доминатора винрейт выше на 7,49 п.п. в показанном срезе. Это наблюдаемая связь, а не эффект покупки.

02 ML научился выделять автоматически размеченные профили. Ранг повышает метрики; независимая точность поиска смурфов неизвестна.

03 LLM создаёт связный обзор, но ошибки ID, таймкодов и выводов мешают использовать текст без проверки.

Каждый кейс продвинулся до наблюдаемого результата. Уровень доказательности различается

Рекомендации и развитие

Приоритет	Действие	Критерий готовности
SQL	Зафиксировать snapshot, фактический медианный порог, фильтры и DQ. Построить кластерный ДИ	Воспроизводимый расчёт N, WR и ΔWR Устойчивость к правилам очистки
ML	Исправить текущий notebook. Проверить автометки, общие матчи train/test и время. Добавить ручной контроль	Повторный run и split manifest Метрики по независимой разметке
LLM	Проверять ID/порядок до zip. Передавать исходные факты в этап 2, валидировать таймкоды и стадии	Нет потери/подмены событий Проверка фактов на нескольких матчах
Эксплуатация	Согласовать код и документацию. Сохранить DAG/run_id, snapshots и измерить SLA	Одна версия решения для защиты Проверяемые логи и паспорта витрин

Приоритеты вытекают из фактических результатов и выявленных ограничений

Командная работа

Участник	Роль	Часть защиты / ответственность*	Передача результата*
Роман Хожанец	BA	Бизнес-вопросы, критерии полезности и границы применения	SA / PA: постановка и гипотезы
Сергей Голдаев	SA	Модель данных, архитектура ключи и гранулярность	DE: контракты таблиц и lineage
Роман Охопков	DE	ETL, STAGE/MART, DQ версии данных и воспроизводимость	PA: витрины, логи и отчёт DQ
Антон Кузьмин	PA	SQL-сравнение, ML/LLM-метрики визуализация и ограничения	Команде: результаты и выводы

* Предлагаемое распределение выступления и передачи артефактов, не атрибуция авторства

ФИО и роли — requirements/team.md. Фактический индивидуальный вклад команда подтверждает